Paměť agenta: co uložit, co vybavit

30 minut • workshop pro vývojáře

- Cíl: zvolit strukturu podle otázky a rozpočtu kontextu.
- Budeme předpovídat výsledky, procházet důkazy a měnit top-k.
- Paměť zde = uložená data + pravidla zápisu + vybavení do promptu.

Tři různé rozpočty

Nezaměňujme kontext, úložiště a RAM

- Kontext LLM: tokeny vybraných důkazů a instrukcí.
- Úložiště: původní text + metadata + embeddingy / hrany.
- RAM a latence: index, cache, retrieval, případně model.
- Menší retrieval neznamená automaticky správnější odpověď.

Menu struktur

Paměť není jen databáze

- Okno historie: přesné nedávné události; staré informace vypadnou.
- Summary: krátký přehled; při kompresi může zmizet podmínka či zdroj.
- JSON / SQL: aktuální stav, preference, verze a přesné filtry.
- Episody + vektory: podobné zkušenosti a neformální text.
- Knowledge Graph: entity, typované vztahy, cesty a provenience.

Stejná data, jiné otázky

Tři provozní úlohy

- A • Jak se řešil podobný connection-pool timeout?
- B • Na čem svc-0 závisí a který tým eskalovat?
- C • Kdo je aktuální vlastník svc-0 po migraci?
- Tipněte si: vektor, graf, nebo přesný stav?

Knowledge Graph × vektorový index

Podobnost není vztah

- Vektor: dotaz → podobné texty → top-k. Přirozený text, parafráze, epizody.
- Graf: entita → typované hrany → sousedé / cesty. Vazby, dopady, zdroje.
- Vektor potřebuje metadata pro čas, tenant a autoritu.
- Graf potřebuje extrakci, sjednocení entit a správné směry hran.
- Obě varianty mohou používat stejné SQL úložiště.

Živá ukázka: najdi chybějící hranu

Nejdřív tip, potom důkazy

- Otevřete ukázku níže nebo demo.html.
- Zvolte B a porovnejte vector s graph.
- Zvolte A: samotný graf nemá vyhledávač epizod.
- Skutečný kód: source-demo.html — import → reexport → normalize.

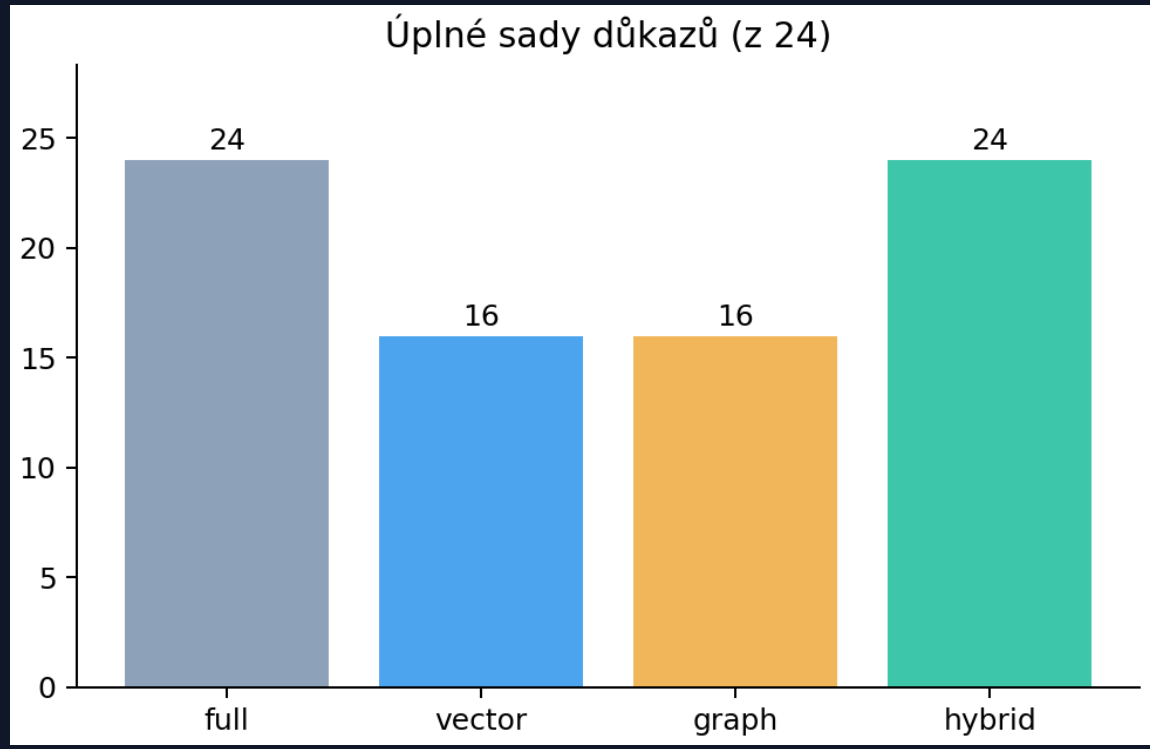
Jak jsme měřili

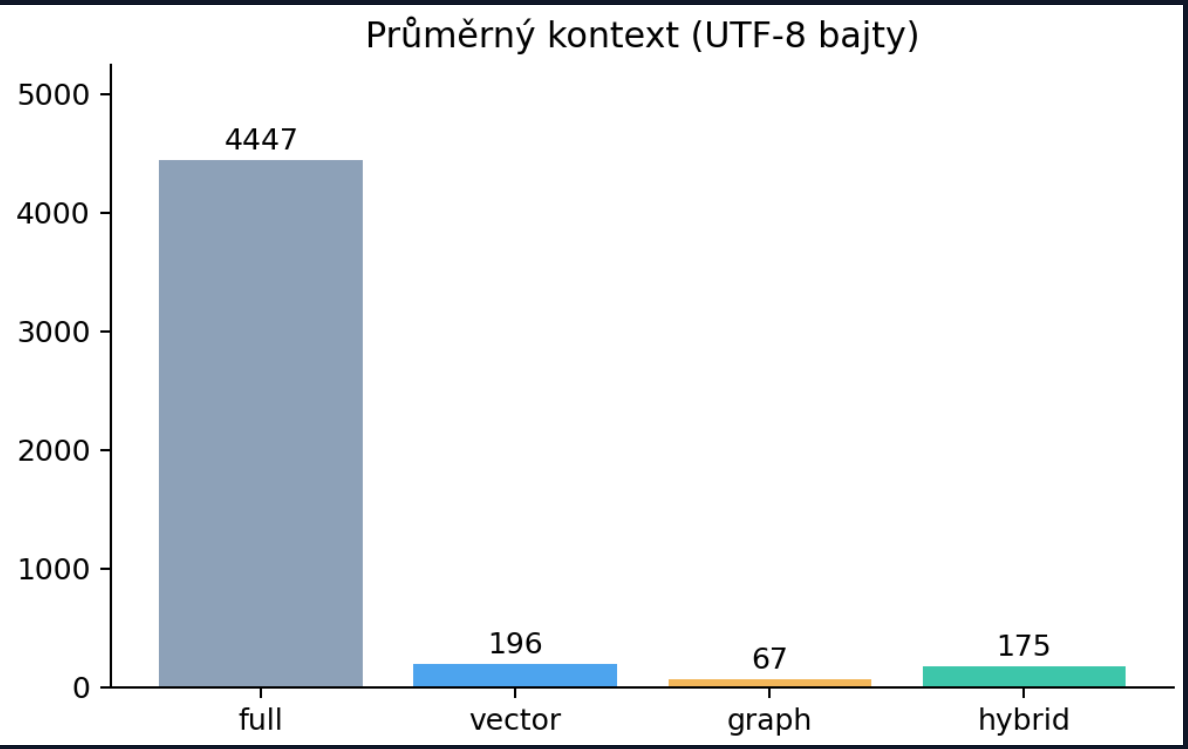
Retrieval, nikoli inteligenci agenta

- 48 dokumentů • 24 dotazů • top-k = 2 • 50 opakování/dotaz.
- Gold = ručně určená ID potřebných důkazů.
- Úplnost = vráceny všechny gold dokumenty; recall = podíl gold.
- Precision = podíl relevantních dokumentů mezi vrácenými.
- Kontext = UTF-8 bajty; čas = warm retrieval v procesu.

Vlastní výsledky

Jeden běh; reprodukovatelné v results.json





Změňme top-k

Více textu může pomoci, ale také zaplnit prompt

- k=1: úplné důkazy 16/24 · 98 B
- k=2: úplné důkazy 16/24 · 196 B
- k=4: úplné důkazy 16/24 · 407 B
- k=8: úplné důkazy 16/24 · 803 B

Hybrid: oddělte text, stav a vazby

Orchestrace je část ceny

- Ulož událost se source_id, entity_id, valid_from/to a autoritou.
- SQL / JSON: aktuální stav; graf: vztahy; vektory: epizody.
- Dotaz → intent + entity → retrieval → deduplikace → budget.
- Ke každému důkazu připoj zdroj, čas a verzi.
- Při konfliktu zdrojů ukaž nejistotu, nedělej tichý overwrite.

Cvičení: návrh paměti pro vašeho agenta

Dvě minuty ve dvojicích

- Agent si pamatuje preference, incidenty a vlastníky služeb.
- Má vracet nejvýše 1 000 tokenů důkazů.
- Navrhněte zápis, retrieval a chování při změně vlastníka.
- Jakým dotazem zjistíte, že návrh selhal?

Rozhodnutí a další experiment

Začněte otázkami, které agent musí zvládnout

- Podobné zkušenosti → textové / vektorové hledání.
- Přesná fakta a aktuální hodnoty → SQL / JSON + časové filtry.
- Více vazeb a dopady → graf, pokud máte kvalitní entity a hrany.
- Kombinujte jen tam, kde testy ukážou přínos.
- Produkčně měřte odpovědi, tokeny, p95, ingest a cenu aktualizací.