Paměť agenta pro podporu obchodníků

30 minut · od dat reportu až k mechanismu výpočtu

- Agent má vysvětlit report, dopady změny kódu a aktuální výpočet skóre.
- Nestačí podobný dokument: potřebujeme zdroje, vazby a správnou verzi.
- Ukážeme stejné otázky přes textové hledání a přes strukturovanou paměť.
- Platforma i klient jsou modeloví; kód a naměřené výsledky jsou přiložené.

Tři otázky: původ dat → dopady feature → aktuální mechanismus finančního zdraví.

Co vlastně šetříme?

Kontext modelu, úložiště a RAM jsou různé věci

- Kontext je text poslaný modelu; delší zadání spotřebuje více tokenů.
- Úložiště drží všechny zdroje a indexy, i když je model právě nevidí.
- RAM je pracovní paměť běžícího systému; latence je čas do výsledku.
- V ukázce měříme délku vybraného textu v bajtech a úplnost důkazů.

Archiv dokumentů zůstává v úložišti; model má dostat jen ověřené podklady ke konkrétnímu reportu.

Pět způsobů uložení

Každá struktura zachovává jiný druh informace

- Historie uchová původní zprávy; souhrn je zkrátí, ale může ztratit výjimku.
- JSON nebo SQL drží přesné hodnoty, například jazyk uživatele a verzi vlastníka.
- Textové epizody popisují zkušenosti; vektory pomohou najít podobný záznam.
- Knowledge Graph propojuje entity vztahy, například služba → databáze → tým.

Profil klienta = přesný stav; incident reportu = zkušenost; report → výpočet → datový zdroj = vztahy.

Tři otázky z podpory tradingu

Každá otázka potřebuje jiný pohled na platformu

- A: „Odkud se berou data pro týdenní report?“ Sledujeme datovou lineage.
- B: „Co ovlivní feature what-if margin?“ Hledáme přímé i nepřímé volající.
- C: „Jaký je současný výpočet finančního zdraví?“ Potřebujeme kód i platnou konfiguraci.
- Ve dvojici tipněte: jaký důkaz by vám k odpovědi nestačil?

Lineage = cesta původu dat. Dopad feature = cesta od měněné funkce k jejím uživatelům.

Vektory versus grafy: odkud jsou data?

Postupně odhalte rozdíl mezi podobností a návazností

VEKTOR · co zní podobně?

TF-IDF: pořadí textů podle slov v otázce

1. doc-weekly-report
   podobnost 0.705
   Popis reportu, ne úplná datová lineage.
2. doc-timeout
   podobnost 0.135
   Zdrojový text / kód; nutno ověřit jeho roli.
3. get_trader_dashboard
   podobnost 0.000
   Zdrojový text / kód; nutno ověřit jeho roli.
4. calculate_liquidity_component
   podobnost 0.000
   Zdrojový text / kód; nutno ověřit jeho roli.

Podobný dokument nemusí obsahovat potřebné důkazy.

Potřebné důkazy: 0/9 · top-4

GRAF + STAV · co je propojené a platné?

Volání kódu, datové zdroje a nasazená verze



Zjednodušená lineage; čte přes load_* funkce.
Profil čte report přímo; pozice také vstupují do skóre.

Potřebné důkazy: 9/9 · úplné

Feature a aktuální mechanismus

Dva další průchody nad stejnou modelovou platformou

VEKTOR · co zní podobně?

TF-IDF: pořadí textů podle slov v otázce

1. doc-feature-proposal
podobnost 0.555
Návrh feature, ne seznam všech volajících míst.

2. calculate_financial_health
podobnost 0.116
Zdrojový text / kód; nutno ověřit jeho roli.

3. health-v1
podobnost 0.047
Zdrojový text / kód; nutno ověřit jeho roli.

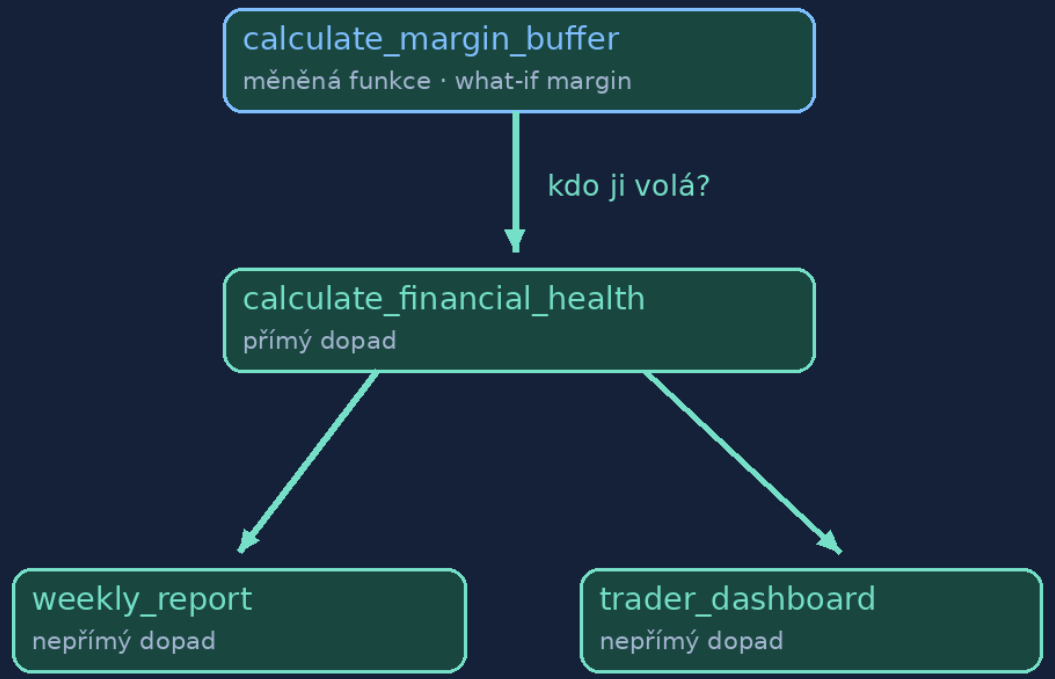
4. health-v2
podobnost 0.046
Zdrojový text / kód; nutno ověřit jeho roli.

Podobný dokument nemusí obsahovat potřebné důkazy.

Potřebné důkazy: 1/3 · top-4

GRAF + STAV · co je propojené a platné?

Volání kódu, datové zdroje a nasazená verze



Směr analýzy je obrácený: od změny k volajícím.

Statický graf neodhalí všechny dynamické vazby.

Potřebné důkazy: 3/3 · úplné

Co jsme opravdu měřili?

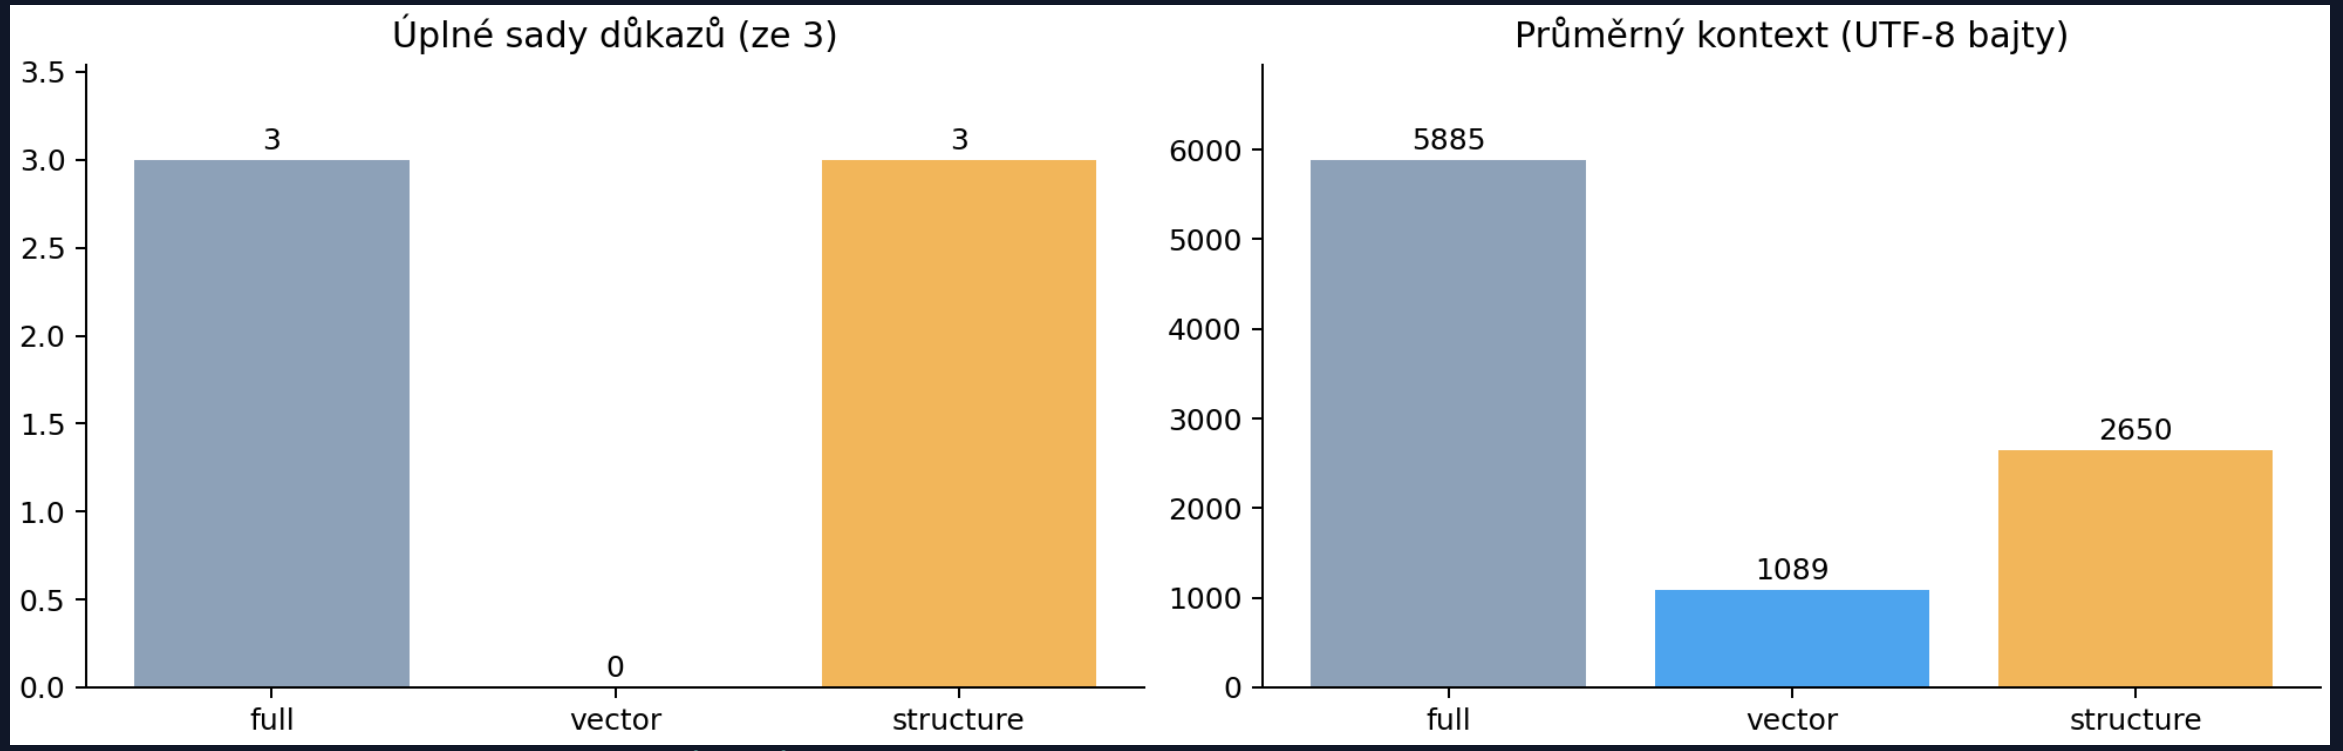
Tři bankovní otázky nad spustitelným modelovým kódem

- Gold je předem určený seznam kódu, konfigurace a zdrojů potřebných k odpovědi.
- Úplnost = všechny důkazy; recall = podíl nalezených potřebných důkazů.
- Srovnáváme celý archiv, TF-IDF top-4 a graf s registrem nasazené verze.
- Měříme bajty podkladů a čas hledání; LLM ani produkty zde neběží.

U dopadů feature potřebujeme 3 důkazy; 1 nalezený znamená recall 1/3 a neúplnou odpověď.

Výsledky bankovní ukázky

Tři diagnostické otázky · nejde o žebříček produktů



Strukturované vybavení vrací více důkazů než top-4; poctivě porovnáváme i množství textu.

Jak se v nástrojích orientovat?

Vybírejte podle otázky, kterou má agent zvládnout

- Graphify a GitNexus mapují kód: kde je funkce a na čem závisí její použití?
- Graphiti řeší fakta měnící se v čase: kdo byl a kdo je vlastníkem?
- Cognee a Mem0 pomáhají s pamětí znalostí, konverzací a uživatelského kontextu.
- LightRAG a Microsoft GraphRAG propojují dokumenty; GraphRAG využívá i souhrny komunit.

Repozitář a dopady feature → Graphify/GitNexus. Historie pravidel → Graphiti + verzovaný stav.

Jak ověřit současný mechanismus?

Registr platnosti + implementace + vstupy výpočtu

VEKTOR · co zní podobně?

TF-IDF: pořadí textů podle slov v otázce

1. doc-health-old
podobnost 0.542
Starší pravidlo: platnost skončila.

2. doc-health-draft
podobnost 0.335
Návrh pravidla: není nasazený.

3. doc-weekly-report
podobnost 0.150
Popis reportu, ne úplná datová lineage.

4. doc-feature-proposal
podobnost 0.085
Návrh feature, ne seznam všech volajících míst.

Podobný dokument nemusí obsahovat potřebné důkazy.

Potřebné důkazy: 0/6 · top-4

GRAF + STAV · co je propojené a platné?

Volání kódu, datové zdroje a nasazená verze



Modelový klient: skóre 54,67 / 100
Výpočet skutečně spustí run_bank_demo.py

Shoda názvu dokumentu ≠ aktuální nasazený mechanismus.

Potřebné důkazy: 6/6 · úplné

Cvičení: agent pro trading platformu

Dvě minuty návrhu + dvě krátké odpovědi

- Agent má vysvětlit původ dat reportu, dopady feature a aktuální mechanismus skóre.
- Pro každou otázku určete potřebné důkazy a způsob jejich vybavení.
- Přidejte test: nový draft nesmí přepsat platné nasazené pravidlo.
- Agent dostane nejvýše 1 000 tokenů podkladů; co zachováte a co vypustíte?

Pomůcka: lineage a dopady v grafu; platnost v registru; popisy a podobné incidenty v textu.

Co si odnést do dalšího návrhu?

Nejdřív otázky a důkazy, potom nástroj

- Podobná zkušenost: začněte hledáním v textu nebo vektorech.
- Přesná hodnota: použijte pojmenovaný stav a kontrolu platnosti.
- Návaznost objektů: použijte explicitní vztahy v grafu nebo tabulkové joiny.
- Kombinaci ověřte na vlastních úlohách: správnost, délka kontextu a cena změn.

Další krok: skutečný report, jedna navržená feature a platný registry mechanismů z vašeho repozitáře.